

Apprentissage profond par renforcement (*Deep RL*)

Laëtitia Matignon

5A - Option Ouverture à la recherche SMA

Apprentissage profond par renforcement (*Deep RL*)

- Apprentissage par renforcement : vous vous souvenez ? ... → rappel au début du CM2
- Réseaux de neurones : vous vous souvenez ? ... → rappel rapide dans le CM1

- Apprentissage automatique : *hot topic* en recherche ... aussi en entreprise ?
- Deep (RL) : *hot topic* en recherche
- Framework d'apprentissage profond : **PyTorch**, Tensorflow, ...



The screenshot shows the header for the International Joint Conference on Artificial Intelligence (IJCAI) 2019, held in Macao from August 10-16, 2019. Below the header, the section 'Accepted papers, by area' lists the number of papers with at least one keyword in various AI fields. The fields and their counts are: Machine learning (2516 submitted, 438 accepted), Computer vision (833 submitted, 117 accepted), Machine learning applications (785 submitted, 144 accepted), Multi-agent systems (518 submitted, 121 accepted), Natural language processing (630 submitted, 103 accepted), Knowledge representation (349 submitted, 88 accepted), Humans and AI (280 submitted, 50 accepted), Planning and scheduling (217 submitted, 48 accepted), Search and game playing (222 submitted, 43 accepted), Uncertainty in AI (185 submitted, 43 accepted), Constraints and satisfiability (128 submitted, 30 accepted), Robotics (127 submitted, 20 accepted), and Multidisciplinary Topics and Applications (617 submitted, 119 accepted).

International Joint Conference
on Artificial Intelligence
August 10-16, 2019

Accepted papers, by area

number of papers with at least one keyword in the area:

- Machine learning: 2516 submitted, accepted 438
- Computer vision: 833 submitted, 117 accepted
- Machine learning applications: 785 submitted, 144 accepted
- Multi-agent systems: 518 submitted, 121 accepted
- Natural language processing: 630 submitted, 103 accepted
- Knowledge representation: 349 submitted, 88 accepted
- Humans and AI: 280 submitted, 50 accepted
- Planning and scheduling: 217 submitted, 48 accepted
- Search and game playing: 222 submitted, 43 accepted
- Uncertainty in AI: 185 submitted, 43 accepted
- Constraints and satisfiability: 128 submitted, 30 accepted
- Robotics: 127 submitted, 20 accepted
- Multidisciplinary Topics and Applications: 617 submitted, 119 accepted

4752 soumissions au total



- bibliothèque logicielle Python open source d'apprentissage machine
- manipuler des tenseurs (tableaux multidimensionnels), les échanger facilement avec Numpy
- effectuer des calculs tensoriels (nécessaire pour l'apprentissage profond) efficaces sur CPU ou GPU
- calculer des gradients pour appliquer facilement des algorithmes d'optimisation par descente de gradient (bibliothèque autograd).

CM1 - Réseaux de neurones et Pytorch

Laëtitia Matignon


5A - Option Ouverture à la recherche SMA

- 1 Introduction
- 2 Rappels : descente de gradient & régression linéaire (NumPy)
- 3 Régression linéaire en PyTorch
- 4 Modèle/NN avec PyTorch
- 5 Application/TP1 : classification supervisée

- 1 Introduction
- 2 Rappels : descente de gradient & régression linéaire (NumPy)
- 3 Régression linéaire en PyTorch
- 4 Modèle/NN avec PyTorch
- 5 Application/TP1 : classification supervisée

Contenu 1er cours


- Rappels sur l'apprentissage supervisé : descente de gradient sur un problème de régression linéaire avec NumPy
- Concepts de base de **PyTorch** illustrés sur un problème de régression linéaire
- Modèle/NN avec PyTorch
- A vous de travailler ! : application des concepts PyTorch sur un problème de **classification supervisée**



 PyTorch

Tenseurs : généralisation des matrices

Tableaux multi-dimensionnels avec éléments tous du même type (vecteur = Tenseur 1D, matrice = Tenseur 2D, ...)



't'
'e'
'n'
's'
'o'
'r'

tensor of dimensions [6]
(vector of dimension 6)

3	1	4	1
5	9	2	6
5	3	5	8
9	7	9	3
2	3	8	4
6	2	6	4

tensor of dimensions [6,4]
(matrix 6 by 4)

2	1	8	2
2	8	4	5
2	3	5	6
7	4	7	1

8	1	8	8
0	9	4	5
0	6	2	8
5	3	2	6

tensor of dimensions [4,4,2]

Tenseurs : généralisation des matrices

NumPy

- bibliothèque pour opérations d'algèbre linéaire
- manipulation de *nd-array*

```
import numpy as np
# initialisation de la graine du
# generateur
np.random.seed(40)
# 2 x 3 ndarray avec nombres aleatoires
# N(0,1)
x = np.random.randn(2,3)
print(x)
print(type(x), x.shape)
```

```
[[ -0.10091345  1.85968363  1.00008287]
 [-2.14836824  1.39821122  0.34256522]]
<class 'numpy.ndarray'> (2, 3)
```

PyTorch



- bibliothèque de calculs tensoriels
- manipulation de *tensor*
- calcul automatique de gradients
- calculs sur CPU ou GPU

```
import torch
# initialisation de la graine du
# generateur
torch.manual_seed(40)
# 2 x 3 Tensor avec nombres aleatoires N
# (0,1)
x = torch.randn(2,3)
print(x)
print(type(x), x.size())
```

```
tensor([[ 0.8529,  0.0279,  0.2130],
        [ 0.5421,  0.1813,  0.9069]])
<class 'torch.Tensor'>
torch.Size([2,3])
```

- 1 Introduction
- 2 Rappels : descente de gradient & régression linéaire (NumPy)
- 3 Régression linéaire en PyTorch
- 4 Modèle/NN avec PyTorch
- 5 Application/TP1 : classification supervisée

Descente de gradient




Algorithme itératif pour trouver le minimum local d'une fonction

- A t on part du point \vec{x}_t
- Le gradient de f , noté $\vec{\nabla} f(\vec{x}_t)$, indique la direction de plus grande pente de f
- Le gradient de f est le vecteur des dérivées partielles de f par rapport à ses paramètres :

$$\vec{\nabla} f(x_1, \dots, x_K) = \left(\frac{\partial f(x_1, \dots, x_K)}{\partial x_1}, \frac{\partial f(x_1, \dots, x_K)}{\partial x_2}, \dots \right)^T$$

- On suit le vecteur donné par le gradient de f en \vec{x}_t
- On passe à $\vec{x}_{t+1} = \vec{x}_t - \lambda \vec{\nabla} f(\vec{x}_t)$ $\lambda > 0$ pas d'apprentissage permet de progresser rapidement au début (en sortant si possible de zones d'optima locaux) puis d'affiner le résultat par des pas plus petits.


Problème de régression linéaire 1D



Apprentissage supervisé : objectif

- f_{θ} fonction cible (**modèle**) à apprendre ($y = f_{\theta}(x) = a + bx$)
- on cherche le vecteur de **paramètres** $\vec{\theta} = [a, b]$ qui permet de *prédire* y à partir de x .

Problème de régression linéaire 1D




```
# Data Generation
np.random.seed(40)
x = np.random.rand(100, 1)
y = 1 + 2 * x + .1 * np.random.randn(100, 1)
# Shuffles the indices
idx = np.arange(100)
np.random.shuffle(idx)
# train set
train_idx = idx[:80]
x_train, y_train = x[train_idx], y[train_idx]
```

Apprentissage supervisé : données d'entrées labellisées

- données d'entrée ou **feature** à une dimension : $\{x_k\}$
- données d'entrée labellisées/**échantillons** : ensemble de N exemples d'entraînement (x_k, y_k) et le reste pour le test

Descente de gradient



```
# x_train : ndarray (80,1)
# Computes our model's predicted output
y_hat = a + b * x_train
# Computes the error
error = (y_train - yhat)
# MSE
loss = (error ** 2).mean()
```

A partir d'un ensemble d'échantillons (x_k, y_k) et des prédictions du modèle $\hat{y}_k = a + bx_k$

1- Calcul de la *loss*

Mean Squared Error

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$


$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - a - bx_i)^2$$

Batch vs stochastic vs mini-batch
gradient descent

Pour le calcul de la *loss* :

- **batch** gradient descent : utilise tous les échantillons d'entraînement (N)
- **stochastic** gradient descent : utilise un seul échantillon
- **mini-batch** gradient descent : utilise $n \in]1; N[$ échantillons

Descente de gradient



```
# Computes the error
error = (y_train - yhat)
# MSE
loss = (error ** 2).mean()
# Computes gradients for both "a" and "b" parameters
a_grad = -2 * error.mean()
b_grad = -2 * (x_train * error).mean()
```

A partir d'un ensemble d'échantillons (x_k, y_k) et des prédictions du modèle $\hat{y}_k = a + bx_k$

1- Calcul de la *loss*

Mean Squared Error

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i) \rightarrow \text{loss à minimiser}$$

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - a - bx_i)$$


2- Calcul du gradient de la *loss*

Dérivées partielles de la *loss* par rapport aux paramètres a, b :

$$\frac{\partial MSE}{\partial a} = \frac{\partial MSE}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial a} = -2 \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)$$

$$\frac{\partial MSE}{\partial b} = \frac{\partial MSE}{\partial \hat{y}_i} \frac{\partial \hat{y}_i}{\partial b} = -2 \frac{1}{N} \sum_{i=1}^N x_i (y_i - \hat{y}_i)$$

Descente de gradient



```
# Computes the error
error = (y_train - yhat)
# MSE loss
loss = (error ** 2).mean()
# Computes gradients for both "a" and "b" parameters
a_grad = -2 * error.mean()
b_grad = -2 * (x_train * error).mean()
# Updates parameters using gradients and learning
rate
a = a - eta * a_grad
b = b - eta * b_grad
```

A partir d'un ensemble d'échantillons (x_k, y_k) et des prédictions du modèle $\hat{y}_k = a + bx_k$

- 1 Calcul de la *loss*
- 2 Calcul du gradient de la *loss*

3- Mise à jour des **paramètres** (une itération de la descente de gradient)

$\eta \in [0; 1]$ learning rate :

$$a = a - \eta \frac{\partial MSE}{\partial a}$$

$$b = b - \eta \frac{\partial MSE}{\partial b}$$

Descente de gradient

4- Itération sur plusieurs epochs

1 **epoch** : tous les échantillons d'entraînement ont été utilisés pour la mise à jour des paramètres :

- **batch** gradient descent : 1 epoch = 1 update
- **stochastic** gradient descent : 1 epoch = N updates
- **mini-batch** gradient descent : 1 epoch = N/n updates (n échantillons par itération)

```
# Defines number of epochs
n_epochs = 1000

for epoch in range(n_epochs):
    # Computes our model's predicted output
    yhat = a + b * x_train

    # Computes the error
    error = (y_train - yhat)
    # MSE loss
    loss = (error ** 2).mean()

    # Computes gradients for both "a" and "b"
    # parameters
    a_grad = -2 * error.mean()
    b_grad = -2 * (x_train * error).mean()

    # Updates parameters using gradients and
    # learning rate
    a = a - lr * a_grad
    b = b - lr * b_grad
```

Conclusion

Descente de gradient : Init + 4 étapes

Initialisation des paramètres et des hyper-paramètres

- ➊ *forward pass* : calcul des **prédictions** \hat{y} du modèle courant
- ➋ Calcul de la *loss*, en utilisant les **prédictions**, **labels** et la **fonction de perte** appropriée à la tâche
- ➌ Calcul du **gradient** - dérivées partielles pour chaque paramètre
- ➍ Mise à jour des paramètres

```
# Random initialization of parameters
np.random.seed(42)
a = np.random.randn(1)
b = np.random.randn(1)

# Initialization of hyper-parameters
# Sets learning rate
lr = 1e-1
# Defines number of epochs
n_epochs = 1000

for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train

    # 2- Computes the error
    error = (y_train - yhat)
    # MSE loss
    loss = (error ** 2).mean()

    # 3- Computes gradients for both "a" and
    # "b" parameters
    a_grad = -2 * error.mean()
    b_grad = -2 * (x_train * error).mean()

    # 4- Updates parameters using gradients
    # and learning rate
    a = a - lr * a_grad
    b = b - lr * b_grad
```

- 1 Introduction
- 2 Rappels : descente de gradient & régression linéaire (NumPy)
- 3 Régression linéaire en PyTorch**
- 4 Modèle/NN avec PyTorch
- 5 Application/TP1 : classification supervisée

NumPy *ndarray* to/from PyTorch *tensor*

- `from_numpy` : transforme *ndarray* en *tensor*

```
import torch

# Numpy arrays transformed into PyTorch's Tensors
# and cast them into lower precision
x_train_tensor = torch.from_numpy(x_train).float()
y_train_tensor = torch.from_numpy(y_train).float()

print(type(x_train), type(x_train_tensor))
```

```
<class 'numpy.ndarray'> <class 'torch.Tensor'>
```

- `numpy()` : transforme *tensor* en *ndarray*

```
x_ndarray = x_train_tensor.numpy()
print(type(x_ndarray))
```

```
<class 'numpy.ndarray'>
```

Création de *tensor* (pour des données)

```
x = torch.rand(3,2)
print(x)
print("x[0]", x[0])
print("x[0][0]", x[0][0])
```

```
tensor([[0.0324, 0.1923], [0.6838, 0.1085], [0.7307, 0.6133]])
x[0] tensor([0.0324, 0.1923])
x[0][0] tensor(0.0324)
```

```
# Resizing
y = x.view(1,-1)
```

```
tensor([[0.0324, 0.1923, 0.6838, 0.1085, 0.7307, 0.6133]])
```

```
x.resize_(2, 3)
```

```
tensor([[0.0324, 0.1923, 0.6838], [0.1085, 0.7307, 0.6133]])
```

Méthodes *in_place*

- Les méthodes qui se terminent par `_` modifient la variable (`resize_`, `add_`, ...).

Création de *tensors* entraînables (pour des paramètres/poids)

Pour préciser à PyTorch qu'il doit **calculer des gradients** par rapport à des tenseurs :

- utiliser l'argument `requires_grad=True` à la création du tenseur
- modifier l'attribut `requires_grad_(True)` à tout moment

```
torch.manual_seed(42)
# Random initialization of parameters
a = torch.randn(1, requires_grad=True, dtype=torch.float)
b = torch.randn(1, requires_grad=True, dtype=torch.float)

print(a)
print(b)

a.requires_grad_(True)
b.requires_grad_(False)
```

```
tensor([0.3367], requires_grad=True)
```

```
tensor([0.1288], requires_grad=True)
```

Autograd (*automatic differentiation*)

module autograd

- Permet le calcul automatique de gradients par rapport à un tenseur
- Mémoire toutes les opérations réalisées sur un tenseur (**graph de calcul dynamique**)

Calcul du gradient / dérivé partielle de la *loss* selon chaque paramètre ($\frac{\partial MSE}{\partial a}$, $\frac{\partial MSE}{\partial b}$) :

- mettre `requires_grad=True` à la création des paramètres (tenseurs)
- invoquer `backward()` sur la *loss*
- remettre les gradients à zéro (ils s'accumulent à chaque appel)

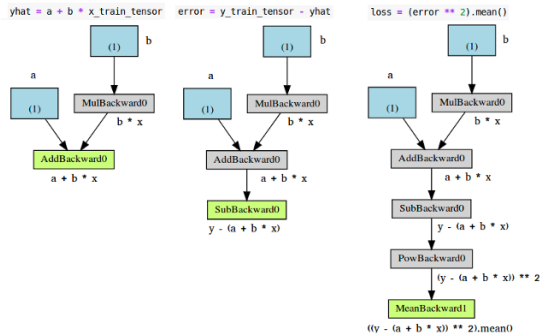
```
# Random initialization of parameters
torch.manual_seed(42)
a = torch.randn(1, requires_grad=True, dtype=
    torch.float)
b = torch.randn(1, requires_grad=True, dtype=
    torch.float)
# Initialization of hyper-parameters
lr = 1e-1
n_epochs = 1000

for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()
    # 3- Computes gradients for both "a" and "
    # b" parameters
    loss.backward()

    # -! No more manual computation of gradients!
    # a_grad = -2 * error.mean()
    # b_grad = -2 * (x_tensor * error).mean()

    a.grad.zero_()
    b.grad.zero_()
```

Graph de calcul dynamique



```
from torchviz import make_dot

torch.manual_seed(42)
a = torch.randn(1, requires_grad=True, dtype=torch.float)
b = torch.randn(1, requires_grad=True, dtype=torch.float)

yhat = a + b * x_train_tensor
error = y_train_tensor - yhat
make_dot(yhat)
make_dot(error)
loss = (error ** 2).mean()
make_dot(loss)
loss.backward()
```

- rectangle bleu : tenseurs sur lesquels on demande à PyTorch de calculer les gradients
- rectangle gris : opérations PyTorch qui impliquent un calcul de gradient
- rectangle vert : comme ci-dessus mais point de départ pour le calcul de gradient si `backward()` est appelé depuis la variable utilisée pour afficher le graph

Graph de calcul dynamique

```

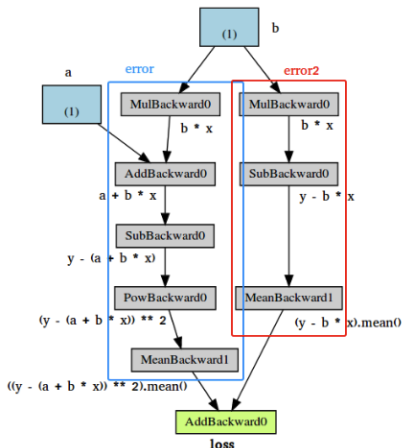
yhat = a + b * x_train_tensor
error = y_train_tensor - yhat

loss = (error ** 2).mean()


if loss > 0:
    yhat2 = b * x_train_tensor
    error2 = y_train_tensor - yhat2

    loss += error2.mean()

```



Graph de calcul dynamique



```
from torchviz import make_dot

torch.manual_seed(42)
a = torch.randn(1, requires_grad=False,
                 dtype=torch.float)
b = torch.randn(1, requires_grad=True, dtype
                 =torch.float)

yhat = a + b * x_train_tensor
make_dot(yhat)
```

- seuls les tenseurs sur lesquels un calcul de gradient doit être fait sont affichés

Autograd (*automatic differentiation*)

module autograd

- Après l'appel à `backward()`, le gradient par rapport à un tenseur est dans l'attribut `.grad` du tenseur
- `.grad_fn` renvoie l'opération qui a créé le tenseur

```
<AddBackward0 object at 0x120474f70>
<SubBackward0 object at 0x120474f70>
<MeanBackward0 object at
0x120474f70>
dMSE/da tensor([-3.1019])
dMSE/db tensor([-1.8132])
```

```
# Random initialization of parameters
torch.manual_seed(42)
a = torch.randn(1, requires_grad=True,
               dtype=torch.float)
b = torch.randn(1, requires_grad=True,
               dtype=torch.float)
# Initialization of hyper-parameters
lr = 1e-1
n_epochs = 1000

for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()

    print(yhat.grad_fn)
    print(error.grad_fn)
    print(loss.grad_fn)

    # 3- Computes gradients for both "a" and "
    # b" parameters
    loss.backward()
    # affichage du gradient calcule par
    # rapport au parametre a
    print("dMSE/da", a.grad)
    print(dMSE/db", b.grad)
```

Autograd (*automatic differentiation*)

Mise à jour des paramètres

Attention à ne pas "perdre" le gradient !

- en ré-assignant un tenseur, son gradient est perdu

dMSE/da avant `tensor([-3.1019])`

dMSE/da apres `None`

`AttributeError: 'NoneType' object has no attribute 'zero_'`

```
for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()

    # 3- Computes gradients for both "a" and "
    # b" parameters
    loss.backward()

    # 4- Update parameters using gradient
    print("dMSE/da avant ", a.grad)
    a = a - lr * a.grad
    b = b - lr * b.grad
    print("dMSE/da apres ", a.grad)

    # gradients are accumulated: zero the
    # gradients
    a.grad.zero_()
    b.grad.zero_()
```

Autograd (*automatic differentiation*)

Mise à jour des paramètres

Attention à ne pas "perdre" le gradient !

- en ré-assignant les tenseurs paramètres
- en utilisant une opération *in-place* sur un paramètre

`RuntimeError: a leaf Variable that requires grad has been used in an in-place operation.`

```
for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    #       predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()

    # 3- Computes gradients for both "a" and "
    #       b" parameters
    loss.backward()

    # 4- Update parameters using gradient
    a -= lr * a.grad
    b -= lr * b.grad

    # gradients are accumulated: zero the
    #       gradients
    a.grad.zero_()
    b.grad.zero_()
```

Autograd (*automatic differentiation*)

Mise à jour des paramètres

Pour réaliser des opérations sur des tenseurs du graph de calcul sans ajouter ces opérations au graph de calcul, on désactive temporairement le graph pour ne pas calculer de gradient :

- `torch.no_grad()` autour d'un bloc de code

```
tensor([0.6469], requires_grad=True)
dMSE/da apres tensor([-3.1019])
```

```
for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    #       predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()

    # 3- Computes gradients for both "a" and "
    #       b" parameters
    loss.backward()

    # 4- Update parameters using gradient
    with torch.no_grad():
        a -= lr * a.grad
        b -= lr * b.grad

    print(a)
    print("dMSE/da apres_", a.grad)

    # gradients are accumulated: zero the
    #       gradients
    a.grad.zero_()
    b.grad.zero_()
```

Autograd (*automatic differentiation*)

`detach` détache un tenseur du graph de calcul.

- `b=a.detach()` : renvoie un nouveau tenseur `b` qui est une copie de `a` détaché du graph de calcul (aucun historique d'opérations, `requires_grad` faux, pas de gradient, ...)

```
a tensor([0.6469],
requires_grad=True)
c tensor([0.6469]) False None
```

```
for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    #       predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()

    # 3- Computes gradients for both "a" and "
    #       b" parameters
    loss.backward()

    # 4- Update parameters using gradient
    #       with torch.no_grad():
    a -= lr * a.grad
    b -= lr * b.grad

    print(a)

    c = a.detach()
    print("c", c, c.requires_grad, c.grad)
```

PyTorch's *optimizer*

Mise à jour des paramètres

Un **optimiseur** (SGD, Adam, ...) met à jour les paramètres :

- ❶ choix de l'optimiseur, des hyper-paramètres et des paramètres à mettre à jour
- ❷ calcul de la mise à jour avec `step()`
- ❸ remise à zéro des gradients avec `zero_grad()`

```
from torch import optim
...
# Defines a SGD optimizer to update the
# parameters
optimizer = optim.SGD([a, b], lr=lr)

for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the error and MSE loss
    error = y_train_tensor - yhat
    loss = (error ** 2).mean()

    # 3- Computes gradients for both "a" and "
    # b" parameters
    loss.backward()

    # 4- Update parameters using gradient
    # No more manual update!
    # with torch.no_grad():
    #     a -= lr * a.grad
    #     b -= lr * b.grad
    optimizer.step()

    # gradients are accumulated: zero the
    # gradients
    optimizer.zero_grad()
```


Calcul de la *loss*

PyTorch propose de nombreuses fonctions de perte, e.g. `MSELoss`

- ❶ choix de la fonction de perte
- ❷ calcul de la *loss*

```
from torch import optim
from torch import nn
...
# Defines a MSE loss function
loss_fn = nn.MSELoss(reduction='mean')

# Defines a SGD optimizer to update the
# parameters
optimizer = optim.SGD([a, b], lr=lr)

for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train_tensor
    # 2- Computes the MSE loss
    # No more manual loss!
    # error = y_tensor - yhat
    # loss = (error ** 2).mean()
    loss = loss_fn(y_train_tensor, yhat)

    # 3- Computes gradients for both "a" and
    # "b" parameters
    loss.backward()

    # 4- Update parameters using gradient
    optimizer.step()

    # gradients are accumulated: zero the
    # gradients
    optimizer.zero_grad()
```

Conclusion

Résumé : Init + 4 étapes par epoch

Initialisation des paramètres et des hyper-paramètres

- ➊ *forward pass* : calcul des **prédictions** du modèle courant
- ➋ Calcul de la *loss*, en utilisant les **prédictions**, **labels** et la **fonction de perte** appropriée à la tâche
- ➌ Calcul du **gradient** - dérivées partielles pour chaque paramètre
- ➍ Mise à jour des paramètres

```
# Random initialization of parameters
torch.manual_seed(42)
a = torch.randn(1, requires_grad=True, dtype=
    torch.float)
b = torch.randn(1, requires_grad=True, dtype=
    torch.float)

# Initialization of hyper-parameters
lr = 1e-1
n_epochs = 1000

# Defines loss function and optimizer
loss_fn = nn.MSELoss(reduction='mean')
optimizer = optim.SGD([a, b], lr=lr)

for epoch in range(n_epochs):
    # 1- forward pass: Computes our model's
    # predicted output
    yhat = a + b * x_train

    # 2- Computes the loss
    loss = loss_fn(y_train_tensor, yhat)

    # 3- Computes gradients for both "a" and
    # "b" parameters
    loss.backward()

    # 4- Updates parameters
    optimizer.step()

    optimizer.zero_grad()
```

- 1 Introduction
- 2 Rappels : descente de gradient & régression linéaire (NumPy)
- 3 Régression linéaire en PyTorch
- 4 Modèle/NN avec PyTorch**
- 5 Application/TP1 : classification supervisée

1 - Modèle avec PyTorch : définition

Représenter la fonction cible à apprendre f_θ .

Héritage de la classe Module

Redéfinir :

- `__init__(self)` : constructeur
- `forward(self, x)` : calcul de la prédiction du modèle pour la feature/entrée x
- utilisation de la classe `Parameter` : récupération d'un itérateur sur les paramètres du modèle (`.parameters()`), des valeurs des paramètres (`state_dict()`), ...

Modèle de régression linéaire 1D $y = f_\theta(x) = a + b * x$

```
from torch import nn

class ManualLinearRegression(nn.Module):
    def __init__(self):
        super().__init__()
        self.a = nn.Parameter(torch.randn(1, requires_grad=True, dtype=torch.float))
        self.b = nn.Parameter(torch.randn(1, requires_grad=True, dtype=torch.float))

    def forward(self, x):
        # Computes the outputs / predictions
        return self.a + self.b * x
```

1- Modèle avec PyTorch : utilisation

La méthode `forward(x)` ne doit pas être appelée, il faut appeler le modèle directement.

train/eval mode

Modèle en mode entraînement ou évaluation car comportements différents (e.g. Dropout, BatchNorm, ...)

```
OrderedDict([('a',
tensor([0.9998])), ('b',
tensor([1.9619]))])
```

```
torch.manual_seed(42)

# Create a model
model = ManualLinearRegression()

lr = 1e-1
n_epochs = 1000

loss_fn = nn.MSELoss(reduction='mean')
# itérateur sur les paramètres
optimizer = optim.SGD(model.parameters(), lr=lr)

for epoch in range(n_epochs):
    model.train()

    # No more manual prediction!
    # yhat = a + b * x_tensor
    # appel implicite de method forward
    yhat = model(x_train_tensor)

    loss = loss_fn(y_train_tensor, yhat)
    loss.backward()
    optimizer.step()
    optimizer.zero_grad()

# Inspect its parameters
print(model.state_dict())
```

2- Modèle avec PyTorch : définition avec Layers de PyTorch

Représenter la fonction cible à apprendre avec un réseau de neurones.

Utilisation des couches prédéfinies (Layers) dans PyTorch

- Linear Layers : `nn.Linear`, `nn.Identity`, ...
- Convolutional Layers : `nn.Conv1D`, `nn.Conv2D`, ...
- Recurrent Layers : `nn.RNN`, `nn.LSTM`, ...

Modèle de régression linéaire 1D $y = f_{\theta}(x) = a + b * x$

Transformation linéaire avec `nn.Linear(input_size,output_size)`.

```
from torch import nn

class LayerLinearRegression(nn.Module):
    def __init__(self):
        super().__init__()
        # Instead of our custom parameters, we use a Linear layer with single input and
        # single output
        self.linear = nn.Linear(1, 1)

    def forward(self, x):
        # Now it only takes a call to the layer to make predictions
        return self.linear(x)
```

Conclusion

Autres concepts de PyTorch

- ➊ création/chargement de Dataset
 - ➋ DataLoader : itération sur dataset
 - ➌ Sauvegarde/Chargement de modèles
 - ➍ Utilisation du GPU
 - ➎ ...
-
- <https://pytorch.org/tutorials/>
 - <https://pytorch.org/docs/stable/nn.html>

- 1 Introduction
- 2 Rappels : descente de gradient & régression linéaire (NumPy)
- 3 Régression linéaire en PyTorch
- 4 Modèle/NN avec PyTorch
- 5 Application/TP1 : classification supervisée

TP1 : classification supervisée

- Installation de **conda** pour la gestion d'environnements virtuels Python
- Utilisation de **jupyter notebook**, *cahier électronique* pouvant contenir du texte, des images, des formules mathématiques et du code informatique exécutable. Ils sont manipulables interactivement dans un navigateur web.
- Deux notebooks contenant le code présenté dans ce CM pour tester
- Un notebook à compléter : NN pour classification Fashion-MNIST

